

Data Quality Platform — Propuesta de Proyecto

1. El Problema

Data quality platform: Es un proyecto que surge de una pregunta y de un problema, cuales son?

Primero, ¿cómo podríamos hacer que el entrenamiento de modelos de inteligencia artificial gastaran menos recursos?

2. ¿Por qué es esto un problema?

Hablemos de recursos en general, como: computacionales y energéticos, ya que hoy en la actualidad (18 de julio de 2026) la inteligencia artificial está en un boom y muchas empresas están trabajando en modelos nuevos, y hay gente especializándose en machine learning las cuales también me imagino que deben de considerar este problema.

A. En Fine-Tuning Empresarial (~75,000 modelos diarios)

- Consumo estándar: Un proceso promedio de fine-tuning corporativo (con técnicas como LoRA) tarda unas 4 horas en un nodo de 4 GPUs A100/H100. Esto equivale a unos 16 kWh por modelo entrenado.[1]
- Consumo global sin optimizar: $75,000 \text{ modelos} \times 16 \text{ kWh} = 1,200,000 \text{ kWh}$ diarios.
- Ahorro con tu enfoque (60% de reducción promedio en tiempo/datos): Se ahorrarían 720,000 kWh al día. Esto equivale a la energía necesaria para abastecer a más de 24,000 hogares promedio durante todo un día.

en emisiones de carbono (Adegoke et al., 2025; De Leon, s.f.). Strubell et al. (s.f.) calcularon que entrenar un único modelo de lenguaje de gran escala puede producir emisiones de CO₂ comparables a las de cinco automóviles durante toda su vida útil.

3. Contexto Científico

Todo el respaldo científico detrás del proyecto el cual es muy util para el desarrollo del proyecto, al cual se le hace énfasis en el artículo.

Yin y Kaynak (2015) señalaron hace ya una década que el paradigma del Big Data ha instalado la idea equivocada de que más datos siempre equivale a mejores modelos. La evidencia muestra lo contrario: un conjunto de datos pequeño pero bien depurado puede superar en rendimiento a uno masivo lleno de ruido. Partiendo de esa premisa, el objetivo de esta investigación es evaluar de forma experimental cómo la mejora en la calidad de los datos afecta el consumo de recursos computacionales y el desempeño predictivo en tres modelos de aprendizaje automático de complejidad variable.

4. ¿Qué descubrió nuestra investigación universitaria?

puntos a tener en cuenta: 3.2.1. Tiempo de entrenamiento

Contra lo que podría esperarse, los datasets depurados tardaron más en entrenar en todos los casos, con incrementos que van del 13,7 % (Diabetes, MLP) al 114,3 % (Adult Income, MLP). La explicación es directa: SMOTE añadió muestras sintéticas para equilibrar las clases, lo que amplió el volumen de datos que procesa el modelo. Este efecto

ya fue documentado por Mohammed et al. (2025), quienes señalan que una preparación rigurosa eleva los costos de la fase inicial pero disminuye los ciclos de re-entrenamiento a lo largo del proyecto.

, Mohammed et al. (2025) comprobaron que los datos ruidosos y redundantes degradan el rendimiento predictivo de manera medible, resultado que este trabajo confirma de forma experimental.

En big data se demuestra que este método de optimización de datos es significativamente más útil, ya que como vemos en la tabla datos como el gasto de co2 y gasto de energía, en los métodos optimizados se reducen hasta un 50% usando un dataset robusto de 500.000 registros (sin utilizar smote).

El patrón energético difiere según la escala del dataset. En los tres datasets pequeños, SMOTE incrementa el número de registros de entrenamiento, lo que eleva el tiempo y la energía por experimento individual en un 30,2 %–105,4 %. Sin embargo, este costo debe leerse como una inversión única: el pipeline de transformación se ejecuta una sola vez por dataset. En producción, con reentrenamiento periódico, el beneficio neto se vuelve positivo a partir de la tercera iteración, pues el modelo OPT. converge con mayor rapidez y necesita menos ciclos de ajuste. En contraste, NetTraffic-BD exhibe un ahorro energético inmediato y sustancial: la reducción dimensional de PCA (21 → 9 componentes) disminuye el tiempo de entrenamiento en 51,1 %, con un ahorro medio de 41,08 J por experimento y una reducción de la huella de carbono de 2,996 mg CO₂-eq por ejecución.

Aca basicamente nos muestra que en small data usando smote, se gastan más recursos pero hace énfasis a que esto se debe ver como una inversión ya que el pipeline de transformación se ejecuta una sola vez por dataset, el beneficio neto se vuelve positivo a partir de la tercera iteración.

En conjunto, los resultados de las secciones 3.2 a 3.6 permiten responder afirmativamente al objetivo de ahorrar energía: el protocolo de optimización sí reduce el consumo computacional en escenarios de Big Data (–51,1 % para NetTraffic-BD), y en datasets pequeños la inversión energética inicial se amortiza en pocas iteraciones gracias a la mejora en rendimiento predictivo que reduce los ciclos de re-entrenamiento fallido. La dualidad —costo inicial vs. ahorro acumulado— configura un argumento de sostenibilidad orientado al ciclo de vida completo del proyecto de IA, coherente con lo propuesto por Ferreira et al. (2026) y con la evidencia cuantitativa presentada en este estudio.

(Aqui se explica lo de la 'inversión' cuando se utilizan datasets small data) ya que mejora el rendimiento predictivo que reduce los ciclos de re-entrenamiento fallido.

El protocolo sí aumentó el tiempo de entrenamiento en los datasets pequeños, con incrementos que van del 13,7 % al 114,3 % según el modelo y el dataset. Esto se debe principalmente a SMOTE, que genera muestras sintéticas para corregir el desbalance de clases y amplió el volumen de datos procesado. Sin embargo, este costo ocurre una sola vez por dataset. En la práctica, observamos que un modelo que desde el principio funciona bien necesita menos ciclos de ajuste y reentrenamiento; en pocas iteraciones ese tiempo adicional de preparación queda compensado.

5. Visión del Proyecto

Vision? Me gustaría construir esa plataforma ya que me parece que el uso excesivo de recursos por entrenar modelos de inteligencia artificial es un problema real en el mundo ya que cada dia se vuelve mas popular la inteligencia artificial y se entrenan muchísimos modelos diariamente.

6. Usuarios Objetivo

Quien usaría esta plataforma? La plataforma estaría principalmente diseñada para ser usada desde por entusiastas de machine learning hasta por alguna empresa que necesite entrenar un modelo y tenga la necesidad de optimizar un data set.

7. ¿Cuándo debería usarse?

Cuando se usaría esta plataforma? lo optimo seria o justo antes de hacer empezar el proceso del machine learning y después de haberlo hecho con un dataset crudo por decirlo así, querer hacer una optimización de recursos sin cambiar de dataset, solo utilizándolo.

8. Flujo de Trabajo Ideal

Flujo ideal? Aun no se tiene muy claro pero seria algo como,

- entrar a la plataforma, poner los filtros (como las restricciones o que se quiere limpiar del dataset exactamente),
- arrastrar el dataset raw a la plataforma
- La plataforma mostrar una estadística o una tabla comparativa de que se podría ahorrar o en específico que se optimizo, con la limpieza de los datos y que criterio así como la precisión, gasto energético o tiempo variaron según los tipos de modelos que se utilicen así como si se utiliza smote o no, también se podría enfatizar en que modelo seria mejor para cada data set pero pues es una idea suelta
- y al final que la persona pueda descargar su dataset ya depurado listo para entrenar un modelo de ia

9. Funciones Principales

Dada la conclusión de un estudio el cual se realizó como proyecto en la universidad: la plataforma debería de funcionar como una plataforma de limpieza y análisis de datasets la cual diagnostique los datasets, dando los datos de valores nulos, repetidos, etc (según el criterio de limpieza que se utilice), Y que tenga la capacidad de dar estadísticas de en que se ahorro, si tiempo, energía, quizá precisión o que fue lo que mejoro o mejorara con la depuración de los datos.

Función estrella de la plataforma: Depurar o optimizar data sets sucios para mejorar el proceso de machine learning.

Que cosas debería detectar?: Valores faltantes - Duplicados - outliers - formatos inválidos.

10. ¿Qué hace diferente a esta plataforma?

Diferenciar: Pues lo que quiero que se diferencie esta plataforma a otras plataformas de simple depuración de datos es que quiero que enfatice en los puntos que más se tocaron en el estudio como los diferentes modelos, el uso del smote y las estadísticas de gasto computacional y de tiempo.

11. Visión a Largo Plazo

Escalabilidad?: Siendo ambicioso y pues partiendo de un proyecto pequeño pero funcional en un futuro se podría hacer a escala mayor y hasta venderse como servicio a empresas que se dediquen al machine learning.

12. Notas de Investigación

Ecuación 1 — Energía consumida por experimento:

$$E(J) = t(s) \times TDP(W) \times \alpha_{util}$$

Ecuación 2 — Huella de carbono:

$$CO_2\text{-eq (g)} = [E \text{ (J)} / 3.600.000] \times PUE \times f_CO_2 \text{ (kg CO}_2\text{/kWh)}$$

Los parámetros adoptados fueron: TDP = 95 W (Intel Xeon E5-2670 v3, equivalente a instancias c5 de AWS); $\alpha_{\text{util}} = 65\%$ (utilización típica en entrenamiento ML en CPU, calibrada con psutil en experimentos piloto); PUE = 1,50 (valor conservador para laboratorio universitario, The Green Grid, 2023); factor de emisión Colombia = 0,175 kg CO₂/kWh (UPME, Balance Energético 2023). Aplicando estas ecuaciones a los 210 experimentos del estudio (180 pequeños + 30 Big Data), la energía total acumulada fue de 5.817,15 J (0,001616 kWh), con una huella de carbono total de 424,17 mg de CO₂-eq.

3.5. Experimento Big Data: NetTraffic-BD (500.000 registros)

Con el fin de evaluar el protocolo de optimización en un escenario de escala real, se incorporó el dataset sintético NetTraffic-BD (500.000 registros, 21 variables), inspirado en el benchmark NSL-KDD de detección de anomalías de tráfico de red. El dataset presenta un alto desbalance de clases (4,2 % de anomalías frente a 95,8 % de tráfico normal) y problemas de calidad introducidos deliberadamente: 90.783 valores faltantes en seis columnas numéricas (~3 %), 4.945 filas duplicadas (~1 %) y más de 2.500 valores extremos en la variable src_bytes (~0,5 %). Dada la escala, no se aplicó SMOTE; en su lugar se utilizó class_weight=balanced en los tres clasificadores y PCA redujo las 21 [variables].

Tabla 5

Consumo energético y huella de carbono por dataset (media sobre todos los modelos y réplicas)

Dataset	Versión	Tiempo medio (s)	Energía media (J)	CO ₂ medio (mg)	ΔE (%)	ΔCO_2 (%)	$\Delta F1\text{-macro}$ (%)
Adult Income	RAW	0,4364	26,95	1,965	—	—	—
Adult Income	OPT.	0,8962	55,34	4,035	+105,4 %*	+105,4 %*	+12,2 %
Diabetes	RAW	0,2214	13,67	0,997	—	—	—
Diabetes	OPT.	0,2884	17,81	1,299	+30,2 %*	+30,2 %*	+16,0 %
Heart Disease	RAW	0,1407	8,69	0,634	—	—	—
Heart Disease	OPT.	0,1880	11,61	0,847	+33,6 %*	+33,6 %*	+11,4 %
NetTraffic-BD (50K)	RAW	1,3016	80,37	5,861	—	—	—
NetTraffic-BD (50K)	OPT.	0,6362	39,29	2,865	-51,1 % ↓	-51,1 % ↓	+27,1 %

Nota. * Para los datasets pequeños, ΔE positivo refleja el overhead de SMOTE (inversión única amortizable). Para NetTraffic-BD, ΔE negativo indica ahorro real por reducción PCA. ↓ = reducción favorable. CO₂ calculado con $f_CO_2 = 0,175$ kg/kWh (UPME 2023, Colombia) y PUE = 1,50.

Para proyectar el impacto a escala operacional se toma NetTraffic-BD como caso de referencia ($\Delta = 41,08$ J/experimento). Considerando un sistema de detección de intrusiones que reentrenaría sus modelos diariamente, el ahorro acumulado mensual (30 días) en función del volumen de reentrenamientos sigue la relación:

$$\text{Ahorro mensual (kWh)} = (n \times 41,08 \times 30) / 3.600.000$$

donde n es el número de reentrenamientos diarios. A 100.000 reentrenamientos/día, el ahorro mensual asciende a 34,24 kWh y a 8.987 mg de CO₂-eq, equivalente a evitar un recorrido de ~52 km en automóvil de combustión. A escala de 1.000.000 reentrenamientos/día, el ahorro alcanza 342,37 kWh/mes y 89,87 g CO₂, comparable al consumo eléctrico diario de un hogar colombiano promedio. Estos números son modestos en términos absolutos para un solo sistema, pero representan un argumento cuantitativo sólido para la adopción de buenas prácticas de ingeniería de datos en organizaciones que operan docenas de pipelines de ML simultáneamente, en línea con los Objetivos de Desarrollo Sostenible (ODS 13) y la agenda de Green AI (Schwartz et al., 2020).

nota: A escala operacional, si un sistema de detección de intrusiones reentrenara sus modelos 100.000 veces al día con datos optimizados en lugar de datos crudos, el ahorro mensual estimado sería de 34,24 kWh y 8.987 mg de CO₂-eq.

13. Ideas para Futuras Versiones

asi como mas funciones que se siguen discutiendo.

entre otros criterios que se siguen evaluando que puedan afectar el proceso del entrenamiento de un modelo.

también se podría enfatizar en que modelo seria mejor para cada data set pero pues es una idea suelta.

Flujo:

